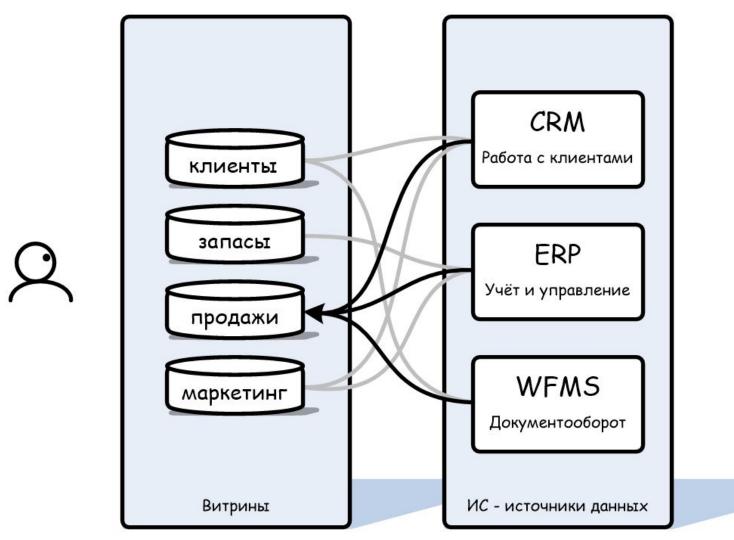
Разработка современных витрин данных и ETLпроцессов

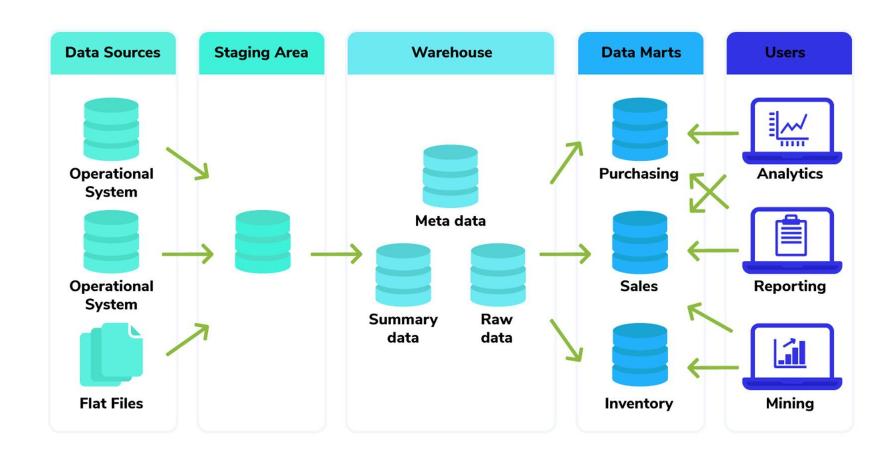
Астахов Сергей ИУ6-22М

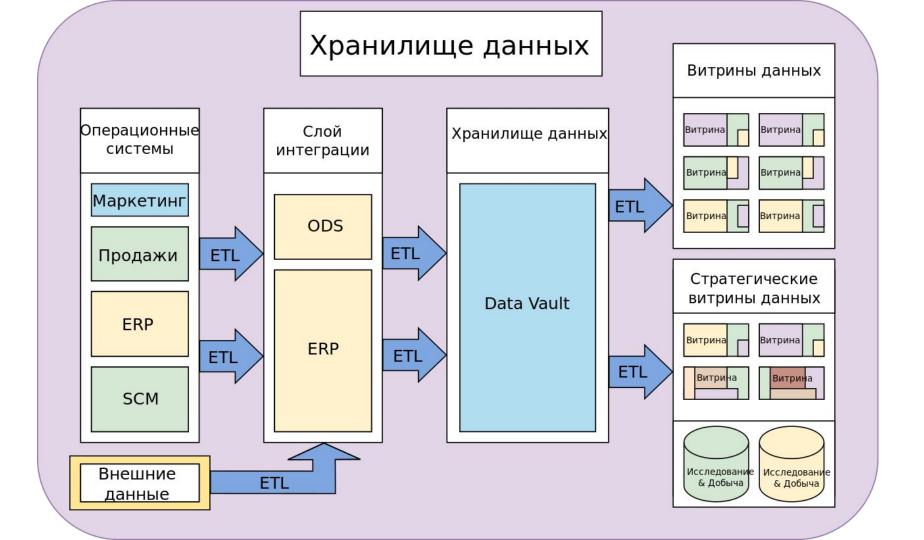
Agenda

- Введение в витрины данных и ETL-процессы
- Версионнсость данных (SCD)
- Оркестрация ETLпроцессов с Apache Airflow

Введение в витрины данных

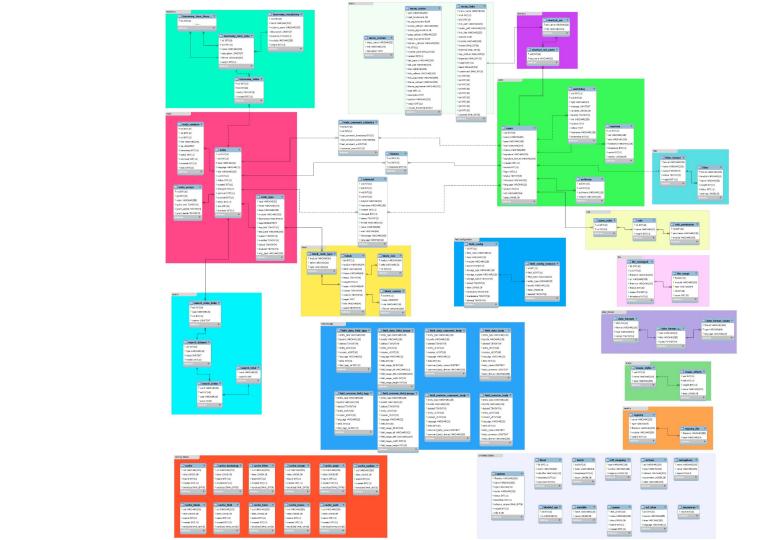






Что не является витриной данных?

- View передает идею, но слишком сложно проектировать (обычно код витрины – это тысячи строк)
- Иерархия view вычисляется при каждом обращении
- Иерархия materialized view
 вычисляется при каждом изменении, причем полностью



Версионнсость данных (SCD)

ID	NAME	POSITION_ID	DEPT	DATE_START	DATE_END
1	Коля	21	2	11.08.2010 10:42:25	01.01.9999
2	Денис	23	3	11.08.2010 10:42:25	01.01.9999
3	Борис	26	2	11.08.2010 10:42:25	01.01.9999
4	Шелдон	22	3	11.08.2010 10:42:25	01.01.9999
5	Пенни	25	2	11.08.2010 10:42:25	01.01.9999

SCD-0 - данные не меняются

SCD-1 - данные полностью перезаписываются

SCD-2 - т.н. effective-версионность (effctive_from/to)

	ID	UPDATE_TIME	LAST_STATE	CURRENT_STATE
1	1	11.08.2010 12:58:48	0	1
2	2	11.08.2010 12:29:16	1	1

Имеет ограниченную историю

ID	NAME	POSITION_ID	DEPT
1	Коля	21	2
2	Денис	23	3
3	Борис	26	2
4	Шелдон	22	3
5	Пенни	25	2

Исторические данные хранятся в отдельной таблице

ID	NAME	POSITION_ID	DEPT	DATE
1	Коля	21	1	11.08.2010 14:12:13
2	Денис	23	2	11.08.2010 14:12:13
3	Борис	26	1	11.08.2010 14:12:13
4	Шелдон	22	2	11.08.2010 14:12:13

Исторические данные хранятся в отдельной таблице

SCD-6 (Гибрид)

VERSION	ID	NAME	POSITION_ID	DEPT	DATE_START	DATE_END	CURRENT
1	1	Коля	21	2	11.08.2010 10:42:25	01.01.9999	1
1	2	Денис	23	3	11.08.2010 10:42:25	01.01.9999	1
1	3	Борис	26	2	11.08.2010 10:42:25	11.08.2010 11:42:25	0
2	3	Борис	26	2	11.08.2010 11:42:26	01.01.9999	1

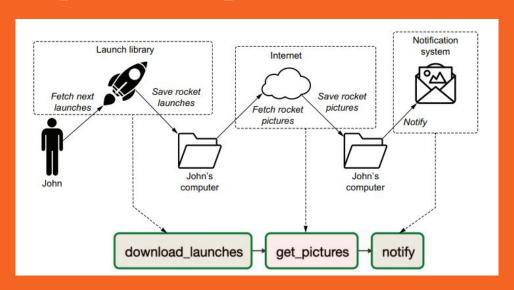
SCD-6. Пример

user_id	zarplata_amt	eff_from	eff_to	version_id	deleted_flg
Vasya	45.000	2001	2999	1	[]
Vasya	60.000	2005	2999	2	[]
Vasya	null	2007	2999	3	[v]

user_id	zarplata_amt	eff_from	eff_to
Vasya	45.000	2001	2004
Vasya	60.000	2005	2006

Оркестрация ETLпроцессов с Apache Airflow

Пример DAG



DAG - порядок выполнения задач

Пример DAG

```
with
DAG('download_rocket_launches',schedule_interval=None,default_args=default_args)
as dag:
  # шаг 1. Загрузка списка запусков
  download_launches=BashOperator(
    task_id='download_launches',
                            bash_command="curl -o /tmp/launches.json"
'https://ll.thespacedevs.com/2.0.0/launch/upcoming/'",
  # шаг 2. Загрузка фото запусков
  get_pictures=PythonOperator(
    task_id='get_pictures',
    python_callable=_get_pictures
```

Пример DAG

```
# шаг 3. Сообщение в консоль
notify=BashOperator(
   task_id='notify',
   bash_command = 'echo "There are now $(ls /tmp/images/ | wc -l) images.")

# зависимости
download_launches >> get_pictures >> notify
```

UI. Список DAG



Docs





DAGs

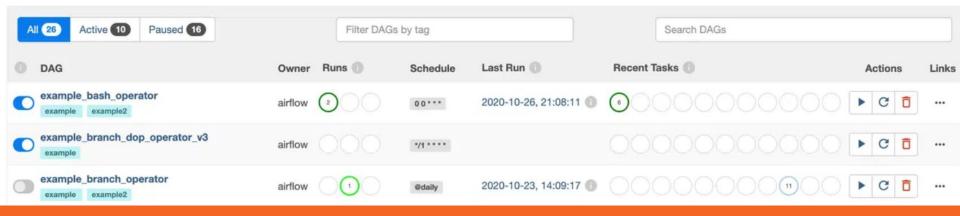
Airflow

DAGS

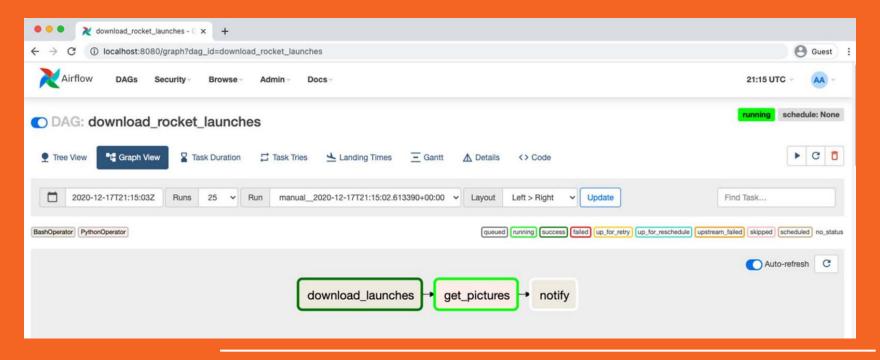
Security

Browse

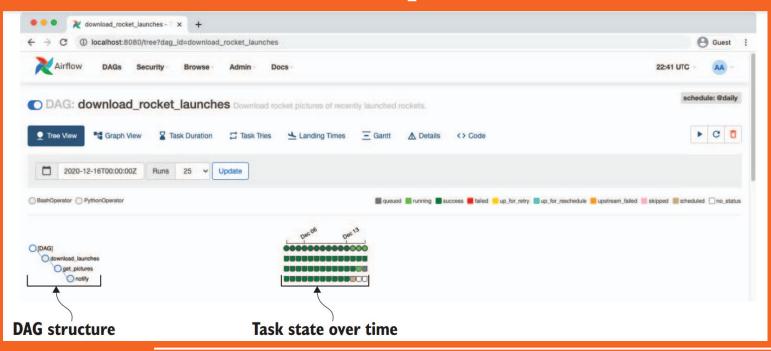
Admin



UI. Исполнение DAG



UI. История DAG



UI. Логи DAG

```
*** Reading local file: /opt/airflow/logs/download_rocket_launches/notify/2020-12-17T21:15:02.613390+00:00/1.log
[2020-12-17 21:15:30,917] {taskinstance.py:826} INFO - Dependencies all met for <TaskInstance: download_rocket_launches.notify 2020-12-17T2
[2020-12-17 21:15:30.923] {taskinstance.py:826} INFO - Dependencies all met for <TaskInstance: download rocket launches.notify 2020-12-17T2
[2020-12-17 21:15:30,923] {taskinstance.py:1017} INFO -
[2020-12-17 21:15:30,923] {taskinstance.pv:1018} INFO - Starting attempt 1 of 1
[2020-12-17 21:15:30,923] {taskinstance.py:1019} INFO -
[2020-12-17 21:15:30.931] {taskinstance.pv:1038} INFO - Executing <Task(BashOperator): notify> on 2020-12-17T21:15:02.613390+00:00
[2020-12-17 21:15:30,933] {standard task runner.pv:51} INFO - Started process 1483 to run task
[2020-12-17 21:15:30,937] {standard task runner.py:75} INFO - Running: ['airflow', 'tasks', 'run', 'download rocket launches', 'notify', '2
[2020-12-17 21:15:30,938] {standard_task_runner.py:76} INFO - Job 6: Subtask notify
[2020-12-17 21:15:30,969] {logging_mixin.py:103} INFO - Running <TaskInstance: download_rocket_launches.notify 2020-12-17T21:15:02.613390+0
[2020-12-17 21:15:30.993] {taskinstance.pv:1230} INFO - Exporting the following env vars:
AIRFLOW CTX DAG OWNER=airflow
AIRFLOW_CTX_DAG_ID=download_rocket_launches
AIRFLOW_CTX_TASK_ID=notify
AIRFLOW CTX EXECUTION DATE=2020-12-17T21:15:02.613390+00:00
AIRFLOW CTX DAG RUN ID=manual 2020-12-17T21:15:02.613390+00:00
[2020-12-17 21:15:30,994] {bash.py:135} INFO - Tmp dir root location:
 /tmp
[2020-12-17 21:15:30,994] {bash.py:158} INFO - Running command: echo "There are now $(ls /tmp/images/ | wc -l) images."
[2020-12-17 21:15:31,002] {bash.py:169} INFO - Output:
[2020-12-17 21:15:31.006] {bash.pv:173} INFO - There are now 2 images.
[2020-12-17 21:15:31,006] {bash.py:177} INFO - Command exited with return code 0
[2020-12-17 21:15:31,021] {taskinstance.py:1135} INFO - Marking task as SUCCESS. dag id=download rocket launches, task id=notify, execution
[2020-12-17 21:15:31,037] {taskinstance.py:1195} INFO - 0 downstream tasks scheduled from follow-on schedule check
[2020-12-17 21:15:31,070] {local_task_job.py:118} INFO - Task exited with return code 0
```

Спасибо за внимание



